Trier les avis clients négatifs par motif : quel modèle ?

Avis Amazon Grocery notés 1 à 3, 6 motifs (un avis peut en porter plusieurs).
Test : 300 avis tirés au hasard, annotés à la main avant toute prédiction ; intervalles de confiance à 95 % par bootstrap.

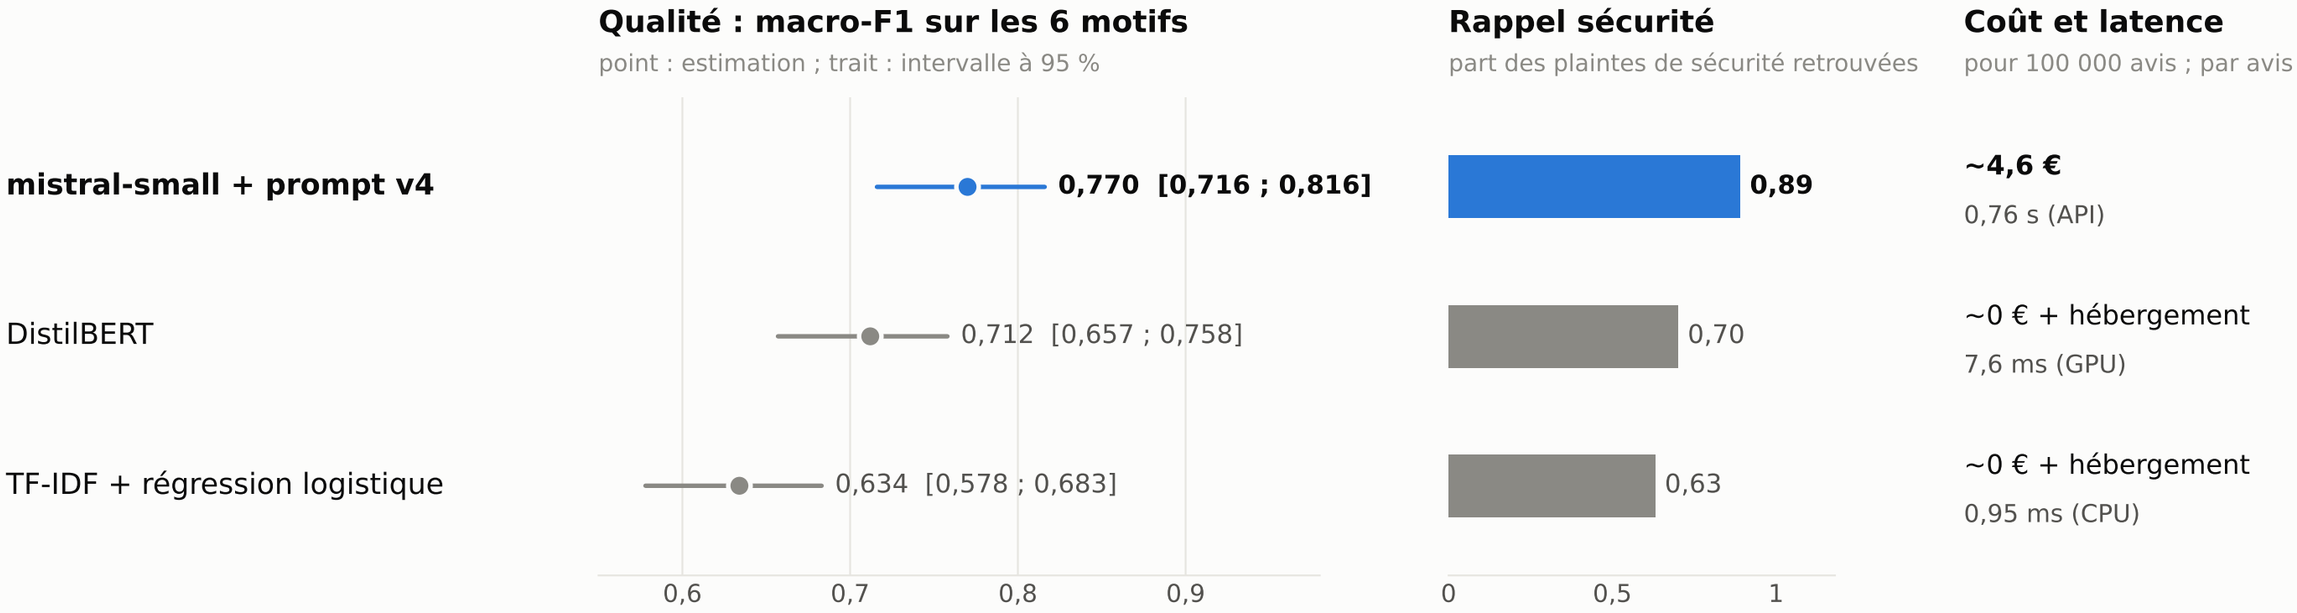

Recommandation : mistral-small (version figée) avec le prompt v4, pour un tri différé

- Meilleure qualité, au niveau d'un annotateur humain comparé à lui-même (accord exact 0,763 contre 0,70).
- Écart avec DistilBERT de −0,058 [−0,115 ; +0,003] en macro-F1, non démontré sur 300 avis ; mais ~3 000 plaintes de sécurité de plus retrouvées pour 100 000 avis (rappel 0,89 contre 0,70).
- Coût réel ~4,6 € pour 100 000 avis : le cache du prompt divise le prix catalogue (14,6 $) par 2,7.
- Conditions : version figée ; 100 avis annotés chaque mois pour suivre la qualité ; DistilBERT en solution de repli.
- Basculer vers DistilBERT si : les données ne doivent pas sortir, temps réel, ou ~1 million d'avis par mois.

Modèles internes entraînés sur 4 979 avis étiquetés par le LLM (distillation). DistilBERT : latence sur GPU T4. Détail des décisions et des chiffres : docs/CONVENTIONS.md.