Trier les avis clients négatifs par motif : quel modèle ?

Avis Amazon Grocery notés 1 à 3, 6 motifs (un avis peut en porter plusieurs).
Test : 300 avis tirés au hasard, annotés à la main avant toute prédiction ; intervalles de confiance à 95 % par bootstrap.

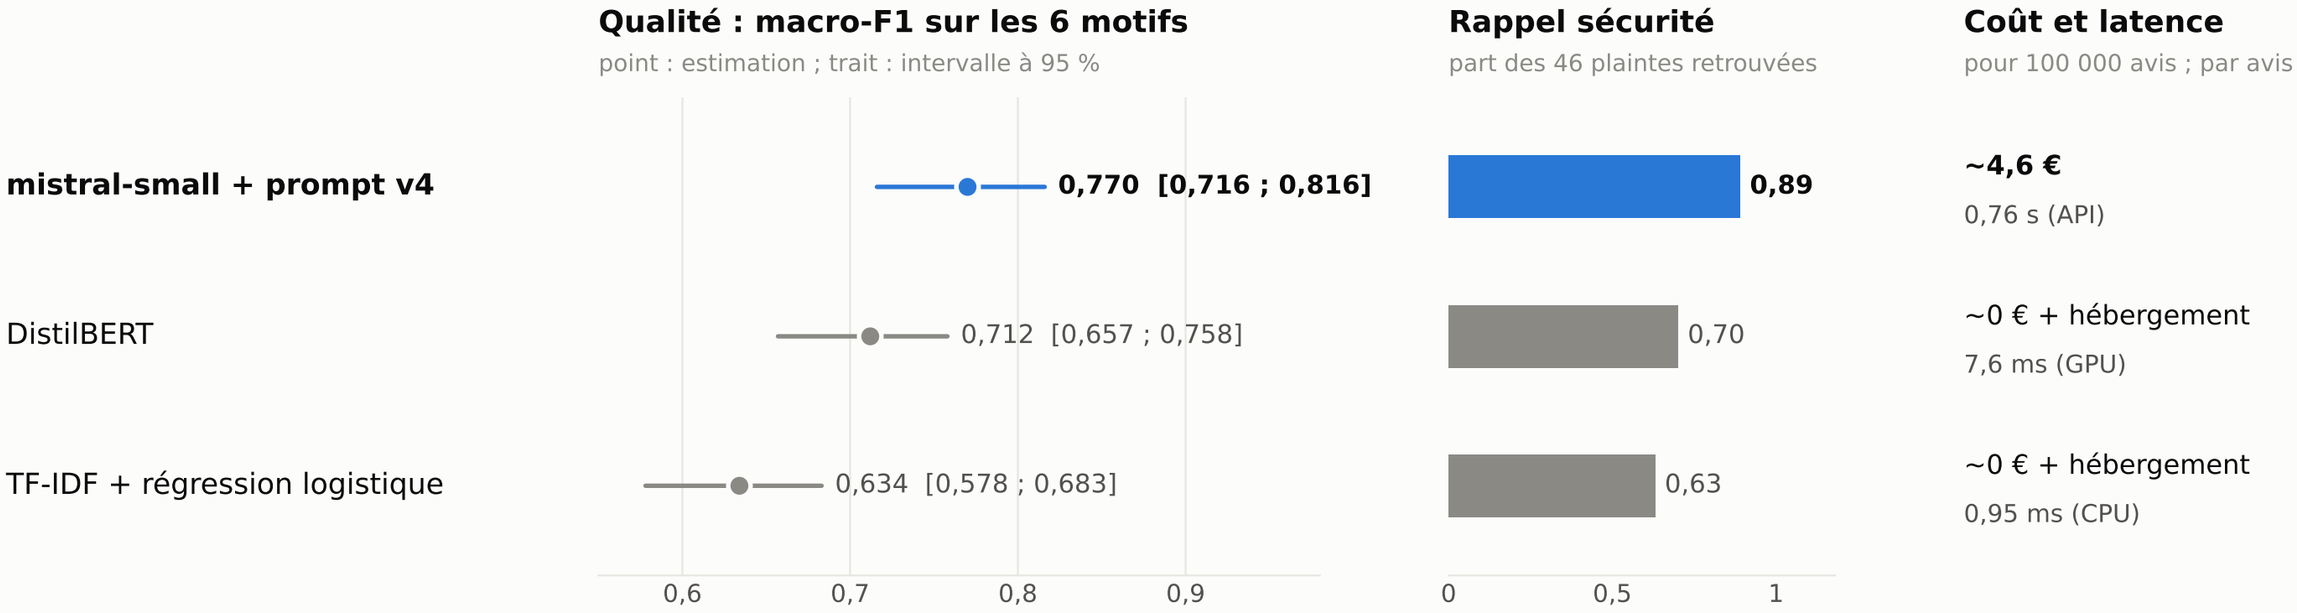

Recommandation : mistral-small (version figée) avec le prompt v4, pour un tri différé

- Meilleur des trois sur chaque métrique de qualité ; contre DistilBERT, écart démontré en accord exact (0,763 contre 0,683).
- Macro-F1 : écart avec DistilBERT de −0,058 [−0,115 ; +0,003], non démontré sur 300 avis.
- Sécurité : rappel 0,89 contre 0,70 (écart +0,20 [+0,07 ; +0,34]), ~3 000 plaintes de plus retrouvées pour 100 000 avis.
- Coût réel ~4,6 € pour 100 000 avis : le cache du prompt divise le prix catalogue (14,6 $) par 2,7.
- Conditions : version figée ; 100 avis annotés chaque mois pour suivre la qualité ; DistilBERT en solution de repli.
- Basculer vers DistilBERT si : les données ne doivent pas sortir, temps réel, ou ~1 million d'avis par mois.

Modèles internes entraînés sur 4 979 avis étiquetés par le LLM (distillation). DistilBERT : latence sur GPU T4. Détail des décisions et des chiffres : docs/CONVENTIONS.md.
Motif sécurité repéré après la mesure de TF-IDF ; avec la correction de Bonferroni sur les 6 motifs, l'écart de rappel reste positif : [+0,02 ; +0,38].